

Entrenamiento de modelos de Machine Learning para predecir la intención de compra de clientes de comercios electrónicos

Santiago Villegas Naranjo¹, Ricardo Medina Herrera¹, and Jenny Andrea Orozco Osorio¹

Abstract—Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magnam aliquam quaerat.

I. INTRODUCCIÓN

En la actualidad, el comercio electrónico se ha convertido en una parte fundamental de la economía digital, cada día, miles de usuarios visitan tiendas en línea, exploran productos y navegan por diferentes páginas, pero no todos terminan realizando una compra. Este comportamiento representa un reto importante para las empresas, ya que entender qué motiva a un usuario a comprar o a no hacerlo puede marcar una gran diferencia en sus estrategias de negocio.

En este trabajo se aborda este problema mediante el uso de técnicas de **Machine Learning**, con el objetivo de analizar el comportamiento de los usuarios durante sus sesiones en un sitio web de e-commerce, a partir de estos datos, se busca construir un modelo capaz de predecir si una sesión terminará en compra o no. Este tipo de predicción puede ser útil en escenarios reales, ya que permitiría a las empresas tomar decisiones en tiempo real, como ofrecer promociones personalizadas o recomendar productos relevantes.

A lo largo del documento se describe el conjunto de datos utilizado, el proceso de análisis y preparación de la información, así como los modelos implementados y su evaluación. Con esto, se espera no solo obtener buenos resultados en la predicción, sino también entender mejor los factores que influyen en el comportamiento de compra de los usuarios.

II. DESCRIPCIÓN DEL PROBLEMA

A. Descripción del contexto y utilidad de solución de ML

Actualmente en el sector del comercio uno de los mayores retos para las empresas es lograr que la mayoría de las visitas de los clientes a los comercios electrónicos se traduzcan en compras. Aunque muchas personas puedan navegar diariamente por un e-commerce, solo un pequeño porcentaje termina realizando una compra.

El problema abordado en este trabajo consiste en analizar el comportamiento de los usuarios durante sus sesiones en e-commerce durante un periodo de un año para entrenar un modelo que pueda predecir si la sesión de un usuario terminara realizando una compra o no. Resolver esta problema permitiría a las empresas conocer que sesiones no terminarían en compras para poder realizar acciones en tiempo real como ofrecer descuentos personalizados o recomendaciones específicas basadas en los gustos del usuario para mejorar la experiencia de compra. Otro beneficio de resolver el problema sería recomendar a usuarios productos que otros usuarios con estadísticas similares han comprado.

Aquí es donde entra el Machine Learning que jugaría un papel importante, dado que nos permitiría entrenar un modelo capaz de realizar las predicciones donde los datos no son evidentes a simple vista, a partir de esta información del usuario sería posible construir modelos que predigan con alta precisión si la sesión terminará en compra o no.

B. Análisis del dataset

El dataset utilizado contiene información de 12,330 sesiones de usuarios, donde cada sesión corresponde a un usuario diferente en un periodo de un año. Esto es importante porque evita que los datos estén sesgados por comportamientos repetitivos de un mismo usuario o fechas especiales como el black friday.

El dataset tiene la característica de ser multivariable y contiene 18 variables, de las cuales ninguno tiene datos faltantes, en la Tabla I podemos observar las distintas variables con su tipo, codificación si aplica y descripción. Los tipos asignados a algunas variables difieren respecto a los descriptos en la metadata del dataset, porque en la medata hay variables con tipo Integer que entre sus filas tienen valores continuos.

En términos de la variable objetivo *Revenue*, el dataset presenta un desbalance donde:

- 10,422 sesiones (84.5% de las sesiones incluidas en el dataset) no terminaron en compra.
- 1,908 sesiones (15.5% de las sesiones incluidas en el dataset) si terminaron en compra.

Este desbalance implica que los modelos podrían tender a predecir más la clase negativa, por lo que es importante tenerlo en cuenta al momento de entrenar y evaluar los modelos.

¹Villegas Naranjo, Medina Herrera, Orozco Osorio are with Facultad de ingeniería, Ingeniería de Sistemas, Universidad de Antioquia, Medellín, {santiago.villegasn, ricardo.medinah, jennya.orozco}@udea.edu.co.

TABLA I. DETALLES DE VARIABLES DEL DATASET

Variable	Tipo	Codificación	Descripción
Administrative	Integer	No aplica	Número de páginas de tipo administrativo visitadas en la sesión.
Administrative_Duration	Continuous	No aplica	Tiempo total en segundos que el usuario permanece en páginas administrativas.
Informational	Integer	No aplica	Número de páginas informativas visitadas en la sesión.
Informational_Duration	Continuous	No aplica	Tiempo total en segundos que el usuario permanece en páginas informativas.
ProductRelated	Integer	No aplica	Número de páginas de producto visitadas en la sesión.
ProductRelated_Duration	Continuous	No aplica	Tiempo total que el usuario permanece en páginas de producto.
BounceRates	Continuous	No aplica	Porcentaje de sesiones en las que el usuario entra al sitio desde una pagina y la abandona sin interactuar con otros elementos durante la misma sesión.
ExitRates	Continuous	No aplica	Porcentaje de visitas a una página específica que resultan ser la ultima interacción del usuario en la sesión.
PageValues	Continuous	No aplica	Valor promedio estimado de una página en términos de contribución a una transacción de e-commerce antes de que esta se complete.
SpecialDay	Continuous	No aplica	Indica la proximidad temporal de la visita a una fecha especial, con valores entre 0 y 1 donde 1 representa el punto de mayor cercanía.
Month	Categorical	Label Encoding de 1 a 10	Mes del año en el que se realizó la sesión del usuario.
OperatingSystems	Integer	Label Encoding de 1 a 8	Identificador numérico del sistema operativo utilizado por el usuario durante la sesión.
Browser	Integer	Label Encoding de 1 a 13	Navegador del visitante.
Region	Integer	Label Encoding de 1 a 9	Región geográfica de origen de la sesión.
TrafficType	Integer	Label Encoding de 1 a 20	Fuente de tráfico que dirigió al usuario al sitio.
VisitorType	Categorical	Label Encoding de 1 a 3	Tipo de visitante: nuevo, recurrente u otro.
Weekend	Binary	0: No, 1: Si	Indica si la sesión ocurrió en fin de semana.
Revenue	Binary	0:No compra, 1:Compra	Variable objetivo. Indica si la sesión resultó en compra

C. Paradigma de aprendizaje y justificación

Para abordar el problema, se decidió utilizar un enfoque combinado de paradigmas de aprendizaje supervisado y no supervisado, el primer paradigma se elige gracias a que todas las muestras del dataset tienen etiquetas y el segundo paradigma se elige para realizar una exploración de la estructura de los datos. Por un lado se emplea el aprendizaje supervisado ya que se cuenta con la variable objetivo que sería *Revenue*, ya que el objetivo es predecir si una sesión terminará o no en compra para esto se seleccionaron los siguientes modelos supervisados capaces de realizar clasificaciones:

- 1) Random forest
- 2) SVM(Support Vector Machine)
- 3) MLP(Multi-Layer Perceptron)

Por otro lado, se incluye aprendizaje no supervisado para analizar la estructura de los datos:

- 1) K-Means
- 2) Gaussian Mixture Model (GMM)

La combinación de estos modelos se decidió teniendo en cuenta los trabajos explorados en la Sección III, seleccionando del paradigma supervisado los modelos que obtuvieron buenos resultados y del paradigma no supervisado los modelos que tuvieron mejor sinergia para explorar el conjunto de datos.

Respecto al desbalance del conjunto de datos se utilizará la técnica de SMOTE siguiendo el ejemplo de los trabajos explorados en la Sección III, dado que en los trabajos explorados se pudo observar un efecto positivo en los resultados al resolver este problema.

Finalmente es importante mencionar que se utilizarán la técnica de validación cruzada con el objetivo de obtener los hiperparámetros de los modelos, inicialmente se tienen planeado utilizar 10 folds siguiendo el ejemplo de uno de los trabajos explorados en la Sección III.

III. ESTADO DEL ARTE

El problema de la predicción de intención de compra en entornos de comercio electrónico se ha consolidado bajo un paradigma de aprendizaje supervisado, tratándolo principalmente como una tarea de clasificación binaria para distinguir entre la conversión o el abandono del usuario. Uno de los trabajos fundamentales es el de [1], donde se implementó un sistema basado en técnicas como Random Forest, Support Vector Machines y Multilayer Perceptron. Los autores utilizaron una metodología de validación basada en validación cruzada de diez pliegues repetida para asegurar la robustez de los hallazgos. Las métricas empleadas para evaluar el desempeño incluyeron la exactitud y el F1-score, siendo esta última

crucial para manejar el desbalance de clases. En este estudio, el modelo Multilayer Perceptron, optimizado con un algoritmo de retropropagación resiliente, obtuvo los mejores resultados con una exactitud del 98.7% y un F1-score de 0.895 en la predicción de la intención de compra.

Por otro lado, [2] aborda el problema mediante un enfoque de ensamble utilizando el algoritmo Gradient Boosting Classifier, específicamente XGBoost, en comparación con métodos como árboles de decisión y máquinas de vectores de soporte. La metodología de validación consistió en una partición de datos, utilizando el 70% de la muestra para el entrenamiento y el 30% para la prueba, integrando además la técnica SMOTE para el balanceo de las clases. Para la evaluación del sistema, se emplearon métricas como la exactitud, el área bajo la curva ROC (auROC) y el área bajo la curva de precisión-recall (auPR). Los resultados destacaron la superioridad de XGBoost, logrando una exactitud del 90.65%, un auROC de 0.937 y un auPR de 0.754, lo que confirma la eficacia de los métodos de boosting en este dominio.

En estos trabajos se enfatiza que, debido a la naturaleza desbalanceada de los datos de navegación, métricas como auROC y auPR son fundamentales para determinar la capacidad del modelo de separar las clases y evaluar la calidad de las predicciones positivas. Mientras que auROC analiza la relación entre la tasa de verdaderos positivos y falsos positivos, auPR se centra en la precisión y la exhaustividad. El presente trabajo se alinea con estos antecedentes al adoptar un enfoque supervisado con modelos como Random Forest y Multilayer Perceptron, complementándolos con técnicas no supervisadas como K-Means y Gaussian Mixture Models para el análisis exploratorio y la identificación de patrones de comportamiento subyacentes.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

V. REDUCCIÓN DE DIMENSIONES

VI. EVALUACIÓN

REFERENCIAS

- [1] C. O. Sakar, S. O. Polat, M. Katircioglu, y Y. Kastro, «Real-time prediction of online shoppers' purchasing intention using multilayer perceptron and LSTM recurrent neural networks», *Neural Computing and Applications*, vol. 31, pp. 6893-6908, 2018, [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:13682776>
- [2] Abdullah-All-Tanvir, I. A. Khandokar, A. M. Islam, S. Islam, y S. Shatabda, «A gradient boosting classifier for purchase intention prediction of online shoppers.», *Heliyon*, p. e15163, 2023, [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:257937617>