

# Entrenamiento de modelos de Machine Learning para predecir la intención de compra de clientes de comercios electrónicos

Santiago Villegas Naranjo<sup>1</sup>, Ricardo Medina Herrera<sup>1</sup>, and Jenny Andrea Orozco Osorio<sup>1</sup>

## I. INTRODUCCIÓN

En la actualidad, el comercio electrónico se ha convertido en una parte fundamental de la economía digital, cada día, miles de usuarios visitan tiendas en línea, exploran productos y navegan por diferentes páginas, pero no todos terminan realizando una compra. Este comportamiento representa un reto importante para las empresas, ya que entender qué motiva a un usuario a comprar o a no hacerlo puede marcar una gran diferencia en sus estrategias de negocio.

En este trabajo se aborda este problema mediante el uso de técnicas de **Machine Learning**, con el objetivo de analizar el comportamiento de los usuarios durante sus sesiones en un sitio web de e-commerce, a partir de estos datos, se busca construir un modelo capaz de predecir si una sesión terminará en compra o no. Este tipo de predicción puede ser útil en escenarios reales, ya que permitiría a las empresas tomar decisiones en tiempo real, como ofrecer promociones personalizadas o recomendar productos relevantes.

A lo largo del documento se describe el conjunto de datos utilizado, el proceso de análisis y preparación de la información, así como los modelos implementados y su evaluación. Con esto, se espera no solo obtener buenos resultados en la predicción, sino también entender mejor los factores que influyen en el comportamiento de compra de los usuarios.

## II. DESCRIPCIÓN DEL PROBLEMA

### A. Descripción del contexto y utilidad de solución de ML

Actualmente, en el sector del comercio uno de los mayores retos para las empresas es lograr que la mayoría de las visitas de los clientes a los comercios electrónicos se traduzcan en compras. Aunque muchas personas puedan navegar diariamente por un e-commerce, solo un pequeño porcentaje termina realizando una compra.

El problema abordado en este trabajo consiste en analizar el comportamiento de los usuarios durante sus sesiones en e-commerce durante un periodo de un año para entrenar un modelo que pueda predecir si la sesión de un usuario terminará

realizando una compra o no. Resolver este problema permitiría a las empresas conocer qué sesiones no terminarán en compras para poder realizar acciones en tiempo real como ofrecer descuentos personalizados o recomendaciones específicas basadas en los gustos del usuario para mejorar la experiencia de compra. Otro beneficio de resolver el problema sería recomendar a usuarios productos que otros usuarios con estadísticas similares han comprado.

Aquí es donde entra el Machine Learning que jugaría un papel importante, dado que nos permitiría entrenar un modelo capaz de realizar las predicciones donde los patrones que hay en ellos no son evidentes a simple vista, a partir de esta información del usuario sería posible construir modelos que predigan con alta precisión si la sesión terminará en compra o no.

### B. Análisis del dataset

El dataset utilizado contiene información de 12,330 sesiones de usuarios, donde cada sesión corresponde a un usuario diferente en un periodo de un año. Esto es importante porque evita que los datos estén sesgados por comportamientos repetitivos de un mismo usuario o fechas especiales como el black friday.

El dataset tiene la característica de ser multivariado y contiene 18 variables, de las cuales ninguno tiene datos faltantes, en la Tabla I podemos observar las distintas variables con su tipo, codificación «si aplica» y descripción. Los tipos asignados a algunas variables difieren respecto a los descritos en la metadata del dataset, porque en la metadata hay variables con tipo Integer que entre sus filas tienen valores continuos.

En términos de la variable objetivo *Revenue*, el dataset presenta un desbalance donde:

- 10,422 sesiones (84.5% de las sesiones incluidas en el dataset) no terminaron en compra.
- 1,908 sesiones (15.5% de las sesiones incluidas en el dataset) sí terminaron en compra.

Este desbalance implica que los modelos podrían tender a predecir más la clase negativa, por lo que es importante tenerlo en cuenta al momento de entrenar y evaluar los modelos.

### C. Paradigma de aprendizaje y justificación

Para abordar el problema, se decidió utilizar un enfoque combinado de paradigmas de aprendizaje supervisado y no supervisado, el primer paradigma se elige gracias a que todas las muestras del dataset tienen etiquetas y el segundo paradig-

<sup>1</sup>Villegas Naranjo, Medina Herrera, Orozco Osorio are with Facultad de ingeniería, Ingeniería de Sistemas, Universidad de Antioquia, Medellín, {santiago.villegasn, ricardo.medinah, jennya.orozco}@udea.edu.co.

TABLA I. DETALLES DE VARIABLES DEL DATASET

| Variable                | Tipo        | Codificación             | Descripción                                                                                                                                             |
|-------------------------|-------------|--------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| Administrative          | Integer     | No aplica                | Número de páginas de tipo administrativo visitadas en la sesión.                                                                                        |
| Administrative_Duration | Continuous  | No aplica                | Tiempo total en segundos que el usuario permanece en páginas administrativas.                                                                           |
| Informational           | Integer     | No aplica                | Número de páginas informativas visitadas en la sesión.                                                                                                  |
| Informational_Duration  | Continuous  | No aplica                | Tiempo total en segundos que el usuario permanece en páginas informativas.                                                                              |
| ProductRelated          | Integer     | No aplica                | Número de páginas de producto visitadas en la sesión.                                                                                                   |
| ProductRelated_Duration | Continuous  | No aplica                | Tiempo total que el usuario permanece en páginas de producto.                                                                                           |
| BounceRates             | Continuous  | No aplica                | Porcentaje de sesiones en las que el usuario entra al sitio desde una pagina y la abandona sin interactuar con otros elementos durante la misma sesión. |
| ExitRates               | Continuous  | No aplica                | Porcentaje de visitas a una página específica que resultan ser la ultima interacción del usuario en la sesión.                                          |
| PageValues              | Continuous  | No aplica                | Valor promedio estimado de una página en términos de contribución a una transacción de e-commerce antes de que esta se complete.                        |
| SpecialDay              | Continuous  | No aplica                | Indica la proximidad temporal de la visita a una fecha especial, con valores entre 0 y 1 donde 1 representa el punto de mayor cercanía.                 |
| Month                   | Categorical | Label Encoding de 1 a 10 | Mes del año en el que se realizó la sesión del usuario.                                                                                                 |
| OperatingSystems        | Integer     | One-hot encoding         | Identificador numérico del sistema operativo utilizado por el usuario durante la sesión.                                                                |
| Browser                 | Integer     | One-hot encoding         | Navegador del visitante.                                                                                                                                |
| Region                  | Integer     | One-hot encoding         | Región geográfica de origen de la sesión.                                                                                                               |
| TrafficType             | Integer     | One-hot encoding         | Fuente de tráfico que dirigió al usuario al sitio.                                                                                                      |
| VisitorType             | Categorical | One-hot encoding         | Tipo de visitante: nuevo, recurrente u otro.                                                                                                            |
| Weekend                 | Binary      | 0: No, 1: Si             | Indica si la sesión ocurrió en fin de semana.                                                                                                           |
| Revenue                 | Binary      | 0:No compra, 1:Compra    | Variable objetivo. Indica si la sesión resultó en compra                                                                                                |

ma se elige para realizar una exploración de la estructura de los datos. Por un lado se emplea el aprendizaje supervisado ya que se cuenta con la variable objetivo que sería Revenue, ya que el objetivo es predecir si una sesión terminará o no en compra, para esto se seleccionaron los siguientes modelos supervisados capaces de realizar clasificaciones:

- 1) Random forest
- 2) XGBoost
- 3) SVM(Support Vector Machine)
- 4) MLP(Multi-Layer Perceptron)
- 5) Logistic Regression
- 6) KNeighborsClassifier

Por otro lado, se incluye aprendizaje no supervisado para analizar la estructura de los datos:

- 1) K-Means
- 2) Gaussian Mixture Model (GMM)

La combinación de estos modelos se decidió teniendo en cuenta los trabajos explorados en la Sección III, seleccionando del paradigma supervisado los modelos que obtuvieron buenos resultados y del paradigma no supervisado los modelos que tuvieron mejor sinergia para explorar el conjunto de datos.

Respecto al desbalance del conjunto de datos se utilizará la técnica de SMOTE siguiendo el ejemplo de los trabajos explorados en la Sección III, dado que en los trabajos explorados se

pudo observar un efecto positivo en los resultados al resolver este problema.

Finalmente es importante mencionar que se utilizarán la técnica de validación cruzada con el objetivo de obtener los hiperparámetros de los modelos, inicialmente se tienen planeado utilizar 10 folds siguiendo el ejemplo de uno de los trabajos explorados en la Sección III.

### III. ESTADO DEL ARTE

El problema de la predicción de intención de compra en entornos de comercio electrónico se ha consolidado bajo un paradigma de aprendizaje supervisado, tratándolo principalmente como una tarea de clasificación binaria para distinguir entre la conversión o el abandono del usuario. Uno de los trabajos fundamentales es el de [1], donde se implementó un sistema basado en técnicas como Random Forest, Support Vector Machines y Multilayer Perceptron. Los autores utilizaron una metodología de validación basada en validación cruzada de diez pliegues repetida para asegurar la robustez de los hallazgos. Las métricas empleadas para evaluar el desempeño incluyeron la exactitud y el F1-score, siendo esta última crucial para manejar el desbalance de clases. En este estudio, el modelo Multilayer Perceptron, optimizado con un algoritmo de retropropagación resiliente, obtuvo los mejores resultados

con una exactitud del 98.7% y un F1-score de 0.895 en la predicción de la intención de compra.

Por otro lado, [2] aborda el problema mediante un enfoque de ensamble utilizando el algoritmo Gradient Boosting Classifier, específicamente XGBoost, en comparación con métodos como árboles de decisión y máquinas de vectores de soporte. La metodología de validación consistió en una partición de datos, utilizando el 70% de la muestra para el entrenamiento y el 30% para la prueba, integrando además la técnica SMOTE para el balanceo de las clases. Para la evaluación del sistema, se emplearon métricas como la exactitud, el área bajo la curva ROC (auROC) y el área bajo la curva de precisión-recall (auPR). Los resultados destacaron la superioridad de XGBoost, logrando una exactitud del 90.65%, un auROC de 0.937 y un auPR de 0.754, lo que confirma la eficacia de los métodos de boosting en este dominio.

En estos trabajos se enfatiza que, debido a la naturaleza desbalanceada de los datos, métricas como auROC y auPR son fundamentales para determinar la capacidad del modelo de separar las clases y evaluar la calidad de las predicciones positivas. Mientras que auROC analiza la relación entre la tasa de verdaderos positivos y falsos positivos, auPR se centra en la precisión y la exhaustividad.

Se integran modelos no supervisados como K-Means con el objetivo de identificar patrones de comportamiento y segmentar las sesiones de usuarios según sus características de navegación. Los grupos obtenidos permitirán analizar si existen perfiles de usuarios con tendencias de compra diferenciadas y complementar la interpretación de los resultados obtenidos por los modelos supervisados. Incluso, esta segmentación podrá utilizarse posteriormente como apoyo en la selección de variables o en la generación de nuevas características para mejorar el desempeño predictivo.

Otro trabajo relevante es [3]. En este estudio se emplea un paradigma de aprendizaje supervisado, abordando el problema como una tarea de clasificación binaria donde se predice si una sesión de navegación terminará o no en una compra. Los autores utilizaron como técnicas principales de aprendizaje automático los algoritmos Random Forest y Support Vector Machine (SVM). Además, el trabajo incluyó procesos de preprocesamiento de datos, codificación de variables categóricas mediante Label Encoding y normalización de variables numéricas utilizando StandardScaler.

La metodología de validación utilizada en [3] consistió en una división del conjunto de datos en entrenamiento y prueba, usando el 80% de las muestras para entrenamiento y el 20% para evaluación. Posteriormente, ambos modelos fueron comparados utilizando diferentes métricas de desempeño. Entre las métricas empleadas se encuentran la exactitud, precisión, exhaustividad, F1-score y el área bajo la curva ROC.

Los resultados obtenidos en [3] mostraron que el modelo Random Forest superó al modelo SVM en la predicción de

intención de compra, alcanzando una exactitud del 90.43% y un valor de área bajo la curva ROC de 0.94, evidenciando una alta capacidad predictiva. Además, el estudio identificó que variables como PageValues y ProductRelated\_Duration fueron las características más influyentes para determinar la intención de compra de los usuarios. Los autores concluyen que un mayor tiempo de interacción con páginas de productos y una mayor interacción con páginas de alto valor incrementan significativamente la probabilidad de conversión en plataformas de comercio electrónico.

Finalmente, en [4] se analiza la predicción de intención de compra mediante técnicas de ensemble learning aplicadas sobre el mismo dataset de Online Shoppers Purchasing Intention. Los autores emplearon un paradigma de aprendizaje supervisado, formulando el problema como una clasificación binaria. Para resolverlo utilizaron modelos como Random Forest, Gradient Boosting, XGBoost y LightGBM, complementados posteriormente con la técnica SMOTE para abordar el desbalance de clases presente en el conjunto de datos. La metodología de validación consistió en dividir los datos en un 70% para entrenamiento y un 30% para pruebas, además de aplicar ajuste de hiperparámetros sobre los modelos finales. Las métricas utilizadas para evaluar el desempeño fueron exactitud, precisión, recall, F1-score y área bajo la curva AUC. Los resultados mostraron que, tras aplicar SMOTE y ajuste de hiperparámetros, el modelo XGBoost alcanzó la mejor exactitud con un 93.54%, mientras que Random Forest obtuvo un AUC de 0.98, evidenciando el impacto positivo de las técnicas de balanceo y ensemble learning sobre el problema de predicción de intención de compra.

#### IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

##### A. Configuración experimental

Para el entrenamiento y evaluación de los modelos, inicialmente el conjunto de datos fue dividido en entrenamiento y prueba utilizando una proporción de 80% y 20%, respectivamente.

Sobre el conjunto de entrenamiento se definió una metodología de validación basada en Stratified K-Fold Cross Validation con 10 particiones. Se decidió utilizar una versión estratificada de validación cruzada en lugar de una validación cruzada convencional debido al desbalance presente en la variable objetivo Revenue. Mientras una validación cruzada tradicional puede generar particiones con distribuciones de clases diferentes entre sí, Stratified K-Fold mantiene aproximadamente la misma proporción de clases en cada fold respecto al dataset original, garantizando una evaluación más estable y representativa del problema.

Para cada uno de los modelos evaluados se implementó un pipeline de entrenamiento compuesto por dos etapas iniciales de preprocesamiento:

- La primera etapa corresponde a la normalización de variables mediante StandardScaler, utilizada para estandarizar la escala de las características y evitar que variables con magnitudes mayores tengan una influencia desproporcionada durante el entrenamiento.
- La segunda etapa corresponde al uso de Synthetic Minority Oversampling Technique (SMOTE), incorporado con el objetivo de reducir parcialmente el desbalance entre clases mediante la generación sintética de nuevas muestras de la clase minoritaria. Se evaluaron distintos porcentajes de sobremuestreo definidos mediante el parámetro `sampling_strategy`, utilizando valores de 0.22, 0.30 y 0.40.

Tanto la normalización como SMOTE fueron integrados dentro del pipeline de entrenamiento con el fin de evitar data leakage. Esto es importante porque las transformaciones de preprocesamiento se ajustan exclusivamente utilizando los datos correspondientes al fold de entrenamiento durante la validación cruzada, de esta manera, los conjuntos de validación permanecen completamente aislados y no influyen en el cálculo de parámetros de escalamiento ni en la generación de muestras sintéticas, evitando estimaciones artificialmente optimistas del desempeño.

Posteriormente, para cada modelo se definió una malla de hiperparámetros específica junto con las configuraciones de SMOTE anteriormente descritas que podemos observar en la Tabla II. El proceso de búsqueda de hiperparámetros se realizó mediante GridSearchCV, utilizando como base el pipeline de entrenamiento y la estrategia de validación definida previamente.

Como métrica principal de optimización durante el entrenamiento se empleó Balanced Accuracy. Esta métrica fue seleccionada debido a la naturaleza desbalanceada del problema, ya que calcula el promedio del recall obtenido sobre cada clase, evitando favorecer artificialmente a la clase mayoritaria. Esto resulta especialmente importante en este problema, donde un modelo podría alcanzar una exactitud elevada simplemente prediciendo predominantemente la clase de sesiones sin compra.

#### B. Resultados del entrenamiento de modelos

Los resultados obtenidos durante el entrenamiento permitieron identificar, para cada modelo evaluado, la mejor combinación de hiperparámetros de acuerdo con la métrica de optimización utilizada, podemos observar estos resultados en la Tabla III.

Para las mejores tres configuraciones de hiperparámetros se registraron los valores de Balanced Accuracy obtenidos tanto en entrenamiento como en validación cruzada, permitiendo analizar la estabilidad del modelo y posibles indicios de sobreajuste o subajuste entre ambos escenarios. Adicionalmente, sobre el conjunto de prueba se calcularon las métricas ROC-

AUC y F1-score, con el objetivo de complementar el análisis del desempeño predictivo. El uso de ROC-AUC permite evaluar la capacidad discriminativa del modelo independientemente del umbral de clasificación seleccionado, mientras que F1-score permite analizar el equilibrio entre precisión y exhaustividad, aspecto especialmente relevante en problemas con distribución desbalanceada de clases.

Los resultados de las mejores configuraciones obtenidas para cada modelo se presentan en la Tabla IV, donde se puede observar el efecto de distintas combinaciones de hiperparámetros sobre el desempeño alcanzado.

Finalmente, para el modelo con mejor rendimiento global se realizó un análisis adicional sobre el conjunto de prueba, en este análisis se incluyó un classification report, con el fin de observar el comportamiento individual de las métricas por clase; el cálculo de intervalos de confianza para las métricas principales; una curva de aprendizaje para estudiar la evolución del desempeño conforme aumenta el tamaño del conjunto de entrenamiento; y una matriz de confusión normalizada que permite visualizar de forma clara la capacidad del modelo para distinguir correctamente entre sesiones con intención de compra y sesiones sin compra.

En la Fig. 1 podemos observar las curvas de aprendizaje para todas las mejores combinaciones de hiperparámetros de los modelos probados.

## V. REDUCCIÓN DE DIMENSIÓN

Con el objetivo de evaluar si era posible disminuir la complejidad del sistema de clasificación sin afectar significativamente su capacidad predictiva, se analizaron diferentes técnicas de reducción de dimensión sobre los dos modelos con mejor desempeño obtenidos en la sección anterior: Random Forest y XGBoost. En particular, se realizó un análisis individual de variables y posteriormente se evaluaron métodos de extracción de características tanto lineales como no lineales mediante PCA y UMAP.

### A. Análisis individual de variables

Como primera etapa, se realizó un análisis individual de las variables del conjunto de datos con el propósito de identificar características con baja capacidad discriminativa y que potencialmente podrían ser eliminadas del modelo. Para ello se emplearon dos métricas complementarias:

- La correlación absoluta de Pearson entre cada variable y la variable objetivo.
- El Information Value (IV), métrica ampliamente utilizada en problemas de clasificación binaria para cuantificar la capacidad predictiva de una variable.

Para interpretar los valores de IV se utilizó la siguiente escala de referencia:

- $IV < 0.02$ : capacidad discriminativa nula o despreciable.

TABLA II. MALLA DE HIPERPARÁMETROS EVALUADA POR MODELO

| Modelo        | Hiperparámetro            | Valores explorados                          |
|---------------|---------------------------|---------------------------------------------|
| Random Forest | max_depth                 | 10, 20                                      |
|               | min_samples_leaf          | 1, 4                                        |
|               | n_estimators              | 200                                         |
|               | max_features              | sqrt                                        |
|               | SMOTE sampling_strategy   | 0.22, 0.30, 0.40                            |
|               | SMOTE k_neighbors         | 3, 5, 7                                     |
| XGBoost       | max_depth                 | 3, 6                                        |
|               | learning_rate             | 0.05, 0.10                                  |
|               | n_estimators              | 200                                         |
|               | subsample                 | 0.8                                         |
|               | colsample_bytree          | 0.8                                         |
|               | SMOTE sampling_strategy   | 0.22, 0.30, 0.40                            |
|               | SMOTE k_neighbors         | 3, 5, 7                                     |
| MLP           | hidden_layer_sizes        | (50,), (100,)                               |
|               | activation                | relu                                        |
|               | alpha (regularización L2) | 0.0001, 0.001                               |
|               | learning_rate_init        | 0.001, 0.01                                 |
|               | SMOTE sampling_strategy   | 0.22, 0.30                                  |
| SVM           | SMOTE k_neighbors         | 5                                           |
|               | kernel                    | linear, rbf                                 |
|               | C                         | 0.01, 0.1, 1                                |
|               | gamma (solo rbf)          | scale, auto, 0.01, 0.1                      |
| GMM           | SMOTE sampling_strategy   | 0.22, 0.30                                  |
|               | n_components              | 1, 2, 3, 4                                  |
|               | covariance_type           | full, diag, tied, spherical                 |
|               | max_iter                  | 100, 200                                    |
|               | n_init                    | 1, 2                                        |
|               | init_params               | kmeans, k-means++, random, random_from_data |
| K-Means       | SMOTE sampling_strategy   | 0.22, 0.30                                  |
|               | n_clusters                | 2, 3, 4, 5                                  |
|               | SMOTE k_neighbors         | 3, 5, 7                                     |
| KNN           | n_neighbors               | 3, 5, 11                                    |
|               | weights                   | uniform, distance                           |
|               | metric                    | euclidean, manhattan                        |
|               | SMOTE sampling_strategy   | 0.22, 0.30, 0.40                            |
|               | SMOTE k_neighbors         | 5                                           |

- $0.02 \leq IV < 0.1$ : capacidad discriminativa débil.
- $0.1 \leq IV < 0.3$ : capacidad discriminativa media.
- $IV \geq 0.3$ : capacidad discriminativa fuerte.

En el caso de las variables continuas, el cálculo del IV se realizó discretizando previamente cada característica en cuan-

tiles. Posteriormente, se definieron los siguientes umbrales para considerar una variable como candidata a eliminación:

- Correlación absoluta de Pearson  $< 0.05$ .
- $IV < 0.02$ .

A partir de este criterio se identificaron 61 variables candidatas a eliminación, debido a que presentaban simultáneamente una

TABLA III. MEJORES COMBINACIONES DE HIPERPARÁMETROS PARA CADA MODELO EVALUADO

| Modelo                 | Hiperparámetros                                                                                                                                           |
|------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Random Forest          | max_depth: 10, max_features: sqrt, min_samples_leaf: 4, n_estimators: 200, k_neighbors para smote: 3, sampling_strategy para smote: 0.3                   |
| XGBoost                | colsample_bytree: 0.8, learning_rate: 0.05, max_depth: 3, n_estimators: 200, subsample: 0.8, k_neighbors para smote: 3, sampling_strategy para smote: 0.3 |
| Multilayer Perceptron  | activation: relu, alpha: 0.001, hidden_layer_sizes: (100,), learning_rate_init: 0.01, k_neighbors para smote: 5, sampling_strategy para smote: 0.22       |
| K-means                | n_clusters: 3, k_neighbors para smote: 7, sampling_strategy para smote: 0.4                                                                               |
| Logistic Regression    | C: 10, penalty: l2, solver: lbfgs, k_neighbors para smote: 3, sampling_strategy para smote: 0.4                                                           |
| KNeighborsClassifier   | metric: euclidean, n_neighbors: 11, weights: distance, k_neighbors para smote: 5, sampling_strategy para smote: 0.4                                       |
| Support Vector Machine | C: 1, kernel: linear, sampling_strategy para smote: 0.3                                                                                                   |
| Gaussian Mixture Model | covariance_type: tied, init_params: random_from_data, max_iter: 200, n_components: 4, n_init: 2, sampling_strategy para smote: 0.22                       |

baja correlación con la variable objetivo y un Information Value prácticamente nulo. Sin embargo, dichas variables no fueron eliminadas directamente, ya que los modelos basados en árboles pueden capturar relaciones no lineales y combinaciones entre variables que no son evidentes mediante análisis univariados.

Los resultados mostraron que las variables con mayor capacidad discriminativa fueron PageValues y Month. Asimismo, PageValues presentó un Information Value de 4.43, lo que indica una fuerte relación con la variable objetivo.

La Fig. 2 muestra las variables con mayor relevancia de acuerdo con ambas métricas, así como los umbrales utilizados para identificar características con baja capacidad discriminativa.

#### B. Extracción de características lineal

Previamente a la aplicación de PCA, los datos fueron normalizados mediante StandardScaler debido a que PCA es sensible a la escala de las variables. Posteriormente, se analizó la varianza acumulada explicada por los componentes principales con el objetivo de seleccionar el número adecuado de componentes.

El criterio utilizado para seleccionar el número de componentes fue conservar al menos el 95 % de la varianza acumulada del conjunto de datos original. Bajo este criterio, fue necesario conservar 54 componentes principales de un total de 65 variables originales, logrando una reducción dimensional del 16.9 %.

En la Fig. 3, los primeros componentes principales concentran gran parte de la variabilidad de los datos, aunque fue necesario conservar una cantidad relativamente alta de componentes para mantener el 95 % de la varianza total.

##### a) Selección del número de componentes principales:

Para determinar el número de componentes principales en PCA, se utilizó como criterio conservar al menos el 95 % de la varianza acumulada del conjunto de datos original. Se seleccionó el umbral del 95 % debido a las siguientes razones:

- Permite conservar la gran mayoría de la información presente en los datos originales.
- Reduce parcialmente la complejidad del espacio de características sin realizar una compresión excesiva.
- Disminuye la redundancia y correlación entre variables originales, ya que los componentes principales son ortogonales entre sí.
- Mantiene una representación suficientemente rica para modelos de clasificación complejos como Random Forest y XGBoost.
- Evita pérdidas significativas de capacidad discriminativa que podrían ocurrir con umbrales más agresivos de reducción.

Para evitar problemas de data leakage durante el entrenamiento y validación de los modelos, PCA fue incorporado directamente dentro del pipeline de entrenamiento junto con las etapas de normalización, SMOTE y clasificación. De esta manera, cada transformación fue ajustada exclusivamente usando los datos correspondientes al fold de entrenamiento durante la validación cruzada.

El orden utilizado dentro del pipeline fue el siguiente:

- 1) Normalización mediante StandardScaler.
- 2) Reducción de dimensión mediante PCA.
- 3) Aplicación de SMOTE para balanceo de clases.
- 4) Entrenamiento del clasificador.

Se reentrenaron los modelos Random Forest y XGBoost utilizando las componentes principales PCA y fueron evaluados usando la misma estrategia de validación cruzada estratificada empleada en la sección anterior.

TABLA IV. RESULTADOS DE LAS MEJORES TRES COMBINACIONES DE HIPERPARÁMETRO PARA CADA MODELO EVALUADO

| Modelo                   | Exactitud balanceada<br>para entrenamiento | Exactitud balanceada<br>para prueba | Área bajo la curva<br>ROC<br>para prueba | F1<br>para prueba |
|--------------------------|--------------------------------------------|-------------------------------------|------------------------------------------|-------------------|
| Random Forest 1          | 0.8979                                     | $0.8543 \pm 0.0140$                 | 0.9103                                   | 0.7785            |
| Random Forest 2          | 0.9029                                     | $0.8541 \pm 0.0137$                 | 0.9114                                   | 0.7734            |
| Random Forest 3          | 0.8749                                     | $0.8540 \pm 0.0144$                 | 0.9096                                   | 0.7634            |
| XGBoost 1                | 0.8427                                     | $0.8345 \pm 0.0097$                 | 0.9175                                   | 0.7827            |
| XGBoost 2                | 0.8405                                     | $0.8341 \pm 0.0124$                 | 0.9177                                   | 0.7812            |
| XGBoost 3                | 0.8405                                     | $0.8339 \pm 0.0098$                 | 0.9177                                   | 0.7812            |
| Multilayer Perceptron 1  | 0.9799                                     | $0.8068 \pm 0.0170$                 | 0.8530                                   | 0.6777            |
| Multilayer Perceptron 2  | 0.9837                                     | $0.8030 \pm 0.0189$                 | 0.8612                                   | 0.6843            |
| Multilayer Perceptron 3  | 0.9990                                     | $0.8028 \pm 0.0193$                 | 0.8641                                   | 0.6957            |
| K-Means 1                | 0.5000                                     | $0.5136 \pm 0.0407$                 | 0.5000                                   | 0.0000            |
| K-Means 2                | 0.5000                                     | $0.5117 \pm 0.0352$                 | 0.5000                                   | 0.0000            |
| K-Means 3                | 0.5000                                     | $0.5108 \pm 0.0325$                 | 0.5000                                   | 0.0000            |
| Logistic Regression 1    | 0.8491                                     | $0.8466 \pm 0.0109$                 | 0.9136                                   | 0.7712            |
| Logistic Regression 2    | 0.8483                                     | $0.8465 \pm 0.0111$                 | 0.9135                                   | 0.7722            |
| Logistic Regression 3    | 0.8482                                     | $0.8444 \pm 0.0121$                 | 0.9141                                   | 0.7718            |
| KNeighborsClassifier 1   | 1.0000                                     | $0.5970 \pm 0.0136$                 | 0.6321                                   | 0.3311            |
| KNeighborsClassifier 2   | 0.7176                                     | $0.5937 \pm 0.0129$                 | 0.6297                                   | 0.3263            |
| KNeighborsClassifier 3   | 1.0000                                     | $0.5874 \pm 0.0159$                 | 0.6120                                   | 0.3103            |
| Support Vector Machine 1 | 0.8364                                     | $0.8339 \pm 0.0102$                 | 0.9132                                   | 0.7785            |
| Support Vector Machine 2 | 0.8333                                     | $0.8334 \pm 0.0092$                 | 0.9131                                   | 0.7805            |
| Support Vector Machine 3 | 0.8231                                     | $0.8219 \pm 0.0109$                 | 0.9129                                   | 0.7675            |
| Gaussian Mixture Model 1 | 0.8311                                     | $0.8099 \pm 0.0093$                 | 0.8423                                   | 0.6667            |
| Gaussian Mixture Model 2 | 0.8311                                     | $0.8099 \pm 0.0093$                 | 0.8423                                   | 0.6667            |
| Gaussian Mixture Model 3 | 0.8311                                     | $0.8099 \pm 0.0093$                 | 0.8423                                   | 0.6667            |

Los resultados en la Tabla V indican que la reducción lineal mediante PCA produjo una disminución considerable en el desempeño de ambos modelos. En particular, se observó una reducción importante en las métricas ROC-AUC, F1-score y Recall. Esto sugiere que parte de la información discriminativa relevante para el problema se encontraba distribuida en componentes de baja varianza que fueron descartadas durante el proceso de reducción.

### C. Extracción de características no lineal

Posteriormente, se evaluó el método UMAP (Uniform Manifold Approximation and Projection) como técnica de reducción de dimensión no lineal. UMAP busca preservar la estructura topológica local de los datos al proyectarlos en un espacio de menor dimensión, permitiendo capturar relaciones no lineales entre las variables.

Al igual que en el caso de PCA, UMAP fue incorporado directamente dentro del pipeline de entrenamiento para evitar problemas de data leakage durante la validación cruzada. El pipeline utilizado siguió el siguiente orden:

- Normalización mediante StandardScaler.
- Reducción de dimensión mediante UMAP.
- Aplicación de SMOTE.
- Entrenamiento del clasificador.

Con el objetivo de seleccionar el número óptimo de componentes UMAP, se evaluaron diferentes configuraciones de dimensionalidad: 2, 5, 10, 15 y 20 componentes como se observa en la Fig. 4. Para cada configuración se calculó el ROC-AUC promedio mediante validación cruzada estratificada utilizando ambos modelos evaluados.











Fig. 1. Curvas de aprendizaje por modelo

El mejor desempeño promedio se obtuvo utilizando 15 componentes, lo que permitió reducir la dimensionalidad original en un 76.9 %.

Se realizó una visualización bidimensional de la representación generada por UMAP para analizar la separación entre clases en el espacio reducido que se puede observar en la Fig.




Fig. 2. Top 20 variables según correlación absoluta de Pearson e Information Value.



TABLA V. COMPARACIÓN DE DESEMPEÑO ENTRE LOS MODELOS BASELINE Y LOS MODELOS CON REDUCCIÓN DE DIMENSIÓN MEDIANTE PCA.

| Modelo           | ROC-AUC CV | Std CV | ROC-AUC Test | Accuracy | F1     | Precisión | Recall | Nº Dimensiones | Reducción (%) |
|------------------|------------|--------|--------------|----------|--------|-----------|--------|----------------|---------------|
| RF baseline      | 0.9106     | 0.0133 | 0.9096       | 0.9262   | 0.7759 | 0.7935    | 0.7590 | 65             | 0%            |
| RF + PCA         | 0.8261     | 0.0082 | 0.8155       | 0.8852   | 0.5368 | 0.8367    | 0.3952 | 54             | 16.9%         |
| XGBoost baseline | 0.9176     | 0.0140 | 0.9167       | 0.9363   | 0.7876 | 0.8981    | 0.7012 | 65             | 0%            |
| XGBoost + PCA    | 0.8325     | 0.0127 | 0.8292       | 0.8966   | 0.5785 | 0.9211    | 0.4217 | 54             | 16.9%         |

TABLA VI. COMPARACIÓN DE DESEMPEÑO ENTRE LOS MODELOS BASELINE Y LOS MODELOS CON REDUCCIÓN DE DIMENSIÓN MEDIANTE UMAP.

| Modelo           | ROC-AUC CV | Std CV | ROC-AUC Test | Accuracy | F1     | Precisión | Recall | Nº Dimensiones | Reducción (%) |
|------------------|------------|--------|--------------|----------|--------|-----------|--------|----------------|---------------|
| RF baseline      | 0.9106     | 0.0133 | 0.9096       | 0.9262   | 0.7759 | 0.7935    | 0.7590 | 65             | 0%            |
| RF + UMAP        | 0.5540     | 0.0137 | 0.5301       | 0.7336   | 0.1798 | 0.1865    | 0.1735 | 15             | 76.9%         |
| XGBoost baseline | 0.9176     | 0.0140 | 0.9167       | 0.9363   | 0.7876 | 0.8981    | 0.7012 | 65             | 0%            |
| XGBoost + UMAP   | 0.5205     | 0.0136 | 0.4985       | 0.8317   | 0.0048 | 0.5000    | 0.0024 | 15             | 76.9%         |




Fig. 3. Varianza explicada por cada componente principal (izquierda) y varianza acumulada en función del número de componentes (derecha). La línea punteada roja indica el umbral del 95% y la línea naranja señala el punto de corte en 54 componentes.




Fig. 4. Selección del número de componentes UMAP mediante ROC-AUC promedio en validación cruzada.




Fig. 5. Representación bidimensional del espacio generado por UMAP.

Los resultados en la Tabla VI muestran que, aunque UMAP logró una reducción dimensional significativamente mayor




Fig. 6. Comparación del ROC-AUC en test para los modelos baseline, PCA y UMAP.

que PCA, el desempeño predictivo de los modelos se degradó considerablemente. Particularmente, las métricas ROC-AUC y F1-score disminuyeron de forma importante, indicando que la representación generada por UMAP no conservó adecuadamente la información discriminativa necesaria para la tarea de clasificación.

Finalmente, al comparar los resultados obtenidos con PCA y UMAP frente a los modelos baseline, se concluye que las técnicas de reducción de dimensión evaluadas no lograron mejorar el desempeño del sistema de clasificación. Aunque PCA y UMAP permitieron reducir el número de variables utilizadas por los modelos, dicha reducción produjo pérdidas importantes de información discriminativa que afectaron negativamente la capacidad predictiva del sistema.

## VI. DISCUSIÓN DE RESULTADOS

Entre los modelos supervisados, XGBoost y Random Forest alcanzaron el mejor desempeño global, con un ROC-AUC en prueba de 0.9175 y 0.9103 respectivamente, seguidos por SVM con 0.9132. El MLP presentó un ROC-AUC de 0.8530, mostrando indicios de sobreajuste dado que su exactitud balanceada en entrenamiento (0.9799–0.9990) supera considerablemente a la de validación (0.8028–0.8068). Los modelos KNN y K-Means obtuvieron el desempeño más bajo, con ROC-AUC de 0.6321 y 0.5000 respectivamente, siendo este último inefi-

caz como clasificador, resultado esperado dada su naturaleza no supervisada.

La Regresión Logística, como modelo paramétrico de referencia, obtuvo un ROC-AUC de 0.9136 en prueba, lo que permite establecer una línea base lineal sobre la cual los modelos más complejos muestran mejora real. La diferencia entre el desempeño de la Regresión Logística y XGBoost confirma que el problema presenta relaciones no lineales que los modelos basados en árboles capturan con mayor eficacia.

La aplicación de PCA con criterio de varianza acumulada del 95% logró una reducción dimensional del 16.9% (de 65 a 54 variables), con un costo en ROC-AUC de test de aproximadamente 0.09 puntos en ambos modelos evaluados (RF y XGBoost). La reducción mediante UMAP, aunque más agresiva (76.9%, de 65 a 15 componentes), produjo una degradación severa del desempeño, con ROC-AUC que cae por debajo de 0.55 en ambos modelos. Esto indica que la información discriminativa del problema está distribuida de forma difusa en el espacio original, y que compresiones no lineales extremas eliminan características relevantes para la clasificación.

Los resultados obtenidos son coherentes con los reportados en la literatura para el mismo conjunto de datos. Sakar et al. [1] reportaron una exactitud del 98.7% y un F1-score de 0.895 con MLP; sin embargo, su configuración no incluyó técnicas de balanceo de clases, lo que puede inflar la exactitud en favor de la clase mayoritaria. Los resultados de este proyecto con XGBoost (ROC-AUC = 0.9175, F1 = 0.7827) son comparables a los obtenidos por Abdullah-All-Tanvir et al. [2] con XGBoost (ROC-AUC = 0.937, F1 implícito de la clase positiva). Las diferencias se explican principalmente por las distintas estrategias de validación: este trabajo emplea validación cruzada estratificada de 10 pliegues, más conservadora que la partición 70/30 usada en [2] y [4].

Alamsyah y Wahyuni [3] reportaron un ROC-AUC de 0.94 con Random Forest, consistente con el valor de 0.9103 obtenido en este trabajo. La pequeña diferencia puede atribuirse a la incorporación de SMOTE, que mejora el recall de la clase minoritaria a expensas de una ligera reducción del ROC-AUC global.

## VII. CONCLUSIONES

Se entrenaron y evaluaron siete modelos de aprendizaje automático para la predicción de intención de compra en sesiones de comercio electrónico. Los principales hallazgos son:

- 1) XGBoost es el modelo con mejor balance entre rendimiento y generalización, con un ROC-AUC de 0.9175 y F1-score de 0.7827 en el conjunto de prueba, sin indicios de sobreajuste significativo.
- 2) La variable `PageValues` es la más discriminativa del conjunto de datos, con un Information Value de 4.43, seguida por las variables de duración en páginas de producto.

- 3) El balanceo de clases mediante SMOTE tuvo un efecto positivo en el recall de la clase minoritaria, siendo el parámetro `sampling_strategy = 0.3` el más frecuentemente seleccionado por GridSearchCV.
- 4) La reducción de dimensión no mejoró el desempeño predictivo en ninguno de los dos modelos evaluados. PCA representa una alternativa aceptable cuando se requiere reducir la complejidad con pérdida mínima de rendimiento; UMAP no es adecuado para este conjunto de datos en contextos de clasificación supervisada.
- 5) K-Means, en su rol exploratorio no supervisado, no logró discriminar entre sesiones con y sin compra, lo que confirma que los clusters naturales del espacio de características no coinciden directamente con las clases de la variable objetivo.

## REFERENCIAS

- [1] C. O. Sakar, S. O. Polat, M. Katircioglu, y Y. Kastro, «Real-time prediction of online shoppers' purchasing intention using multilayer perceptron and LSTM recurrent neural networks», *Neural Computing and Applications*, vol. 31, pp. 6893-6908, 2018, [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:13682776>
- [2] Abdullah-All-Tanvir, I. A. Khandokar, A. M. Islam, S. Islam, y S. Shatabda, «A gradient boosting classifier for purchase intention prediction of online shoppers.», *Heliyon*, p. e15163, 2023, [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:257937617>
- [3] R. Alamsyah y S. Wahyuni, «Using Random Forest and Support Vector Machine Algorithms to Predict Online Shopper Purchase Intention from E-Commerce Session Data», *International Journal for Applied Information Management*, vol. 4, n.º 2, jul. 2024, doi: 10.47738/ijaim.v4i2.81.
- [4] J. Adhikari, «Online Shoppers' Purchase Intention using Ensemble Learning Approach», *International Journal of Next-Generation Computing*, 2023, [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:266249313>